

# DỰ ĐOÁN RỦI RO TẾ NGÃ Ở NGƯỜI CAO TUỔI DỰA TRÊN CẢM BIẾN ĐEO TAY

Vương Đức Tuấn, Vũ Quang Trường, Lỗ Văn Tuấn

Công Nghệ Thông Tin, Đại Học Đại Nam  
Github: [TruongQuangVu2005/DuDoanTeNga](#)

**Tóm tắt:** Tế ngã là một trong những nguyên nhân hàng đầu gây chấn thương nghiêm trọng ở người cao tuổi, ảnh hưởng đến chất lượng cuộc sống và gia tăng chi phí y tế. Việc dự đoán nguy cơ té ngã sớm có thể giúp ngăn ngừa tai nạn và đưa ra biện pháp can thiệp kịp thời. Trong nghiên cứu này, chúng tôi đề xuất sử dụng mô hình kết hợp mạng nơ-ron tích chập (CNN) và LSTM để phân tích dữ liệu từ cảm biến đeo tay và dự đoán rủi ro té ngã. CNN giúp trích xuất đặc trưng từ dữ liệu gia tốc và con quay hồi chuyển, trong khi LSTM xử lý thông tin chuỗi thời gian để nhận diện trạng thái chuyển động. Thử nghiệm được tiến hành trên tập dữ liệu MobiFall Dataset v2.0. Kết quả cho thấy phương pháp đề xuất đạt độ chính xác cao hơn so với các phương pháp truyền thống, đồng thời có tốc độ xử lý nhanh, phù hợp với ứng dụng thời gian thực.

**Từ khoá:** Dự đoán té ngã, CNN, LSTM, MobiFall Dataset, Dữ liệu cảm biến đeo tay I. GIỚI THIỆU

Tế ngã là một trong những nguyên nhân hàng đầu gây chấn thương nghiêm trọng ở người cao tuổi, dẫn đến suy giảm khả năng vận động, giảm chất lượng cuộc sống và tăng chi phí điều trị y tế[1]. Theo thống kê, mỗi năm có hàng triệu ca té ngã được ghi nhận, trong đó nhiều trường hợp gây hậu quả nghiêm trọng như gãy xương, chấn thương sọ não hoặc thậm chí tử vong. Chính vì vậy, việc dự đoán sớm nguy cơ té ngã đóng vai trò quan trọng trong việc ngăn ngừa tai nạn và triển khai các biện pháp can thiệp kịp thời.

Trong những năm gần đây, các hệ thống phát hiện và dự đoán té ngã chủ yếu dựa trên dữ liệu cảm biến đeo

tay, sử dụng gia tốc kế và con quay hồi chuyển để phân tích chuyển động[2]. Tuy nhiên, hầu hết các phương pháp truyền thống như dựa vào ngưỡng gia tốc hoặc các mô hình học máy như SVM, Random Forest vẫn còn nhiều hạn chế, bao gồm độ chính xác chưa cao, khó thích ứng với nhiều tình huống thực tế và khả năng hoạt động trong thời gian thực còn bị giới hạn.

Để khắc phục những vấn đề trên, trong nghiên cứu này, chúng tôi đề xuất một phương pháp kết hợp mạng nơ-ron tích chập (CNN) và LSTM để dự đoán rủi ro té ngã dựa trên dữ liệu cảm biến đeo tay. CNN giúp trích xuất đặc trưng từ dữ liệu cảm biến mà không cần thiết kế thủ công, trong khi LSTM có khả năng xử lý dữ liệu chuỗi thời gian, giúp mô hình nhận diện được các trạng thái chuyển động liên tiếp và dự đoán nguy cơ té ngã một cách chính xác hơn.

Thử nghiệm được tiến hành trên bộ dữ liệu MobiFall Dataset v2.0, bao gồm nhiều tình huống vận động khác nhau của người cao tuổi. Kết quả cho thấy phương pháp đề xuất đạt độ chính xác cao hơn so với các mô hình truyền thống, đồng thời có tốc độ xử lý nhanh, phù hợp với ứng dụng thời gian thực. Nội dung bài báo được trình bày như sau: Phần II giới thiệu tổng quan các nghiên cứu liên quan, Phần III mô tả chi tiết mô hình đề xuất, Phần IV trình bày thử nghiệm và đánh giá kết quả, cuối cùng, Phần V kết luận và đề xuất hướng nghiên cứu tiếp theo.

## II. MỘT SỐ NGHIÊN CỨU LIÊN QUAN

Trong những năm qua, nhiều phương pháp đã được đề xuất để dự đoán nguy cơ té ngã ở người cao tuổi, dựa trên dữ liệu từ cảm biến đeo tay hoặc các thiết bị theo dõi chuyển động. Các phương pháp này có thể được phân loại thành ba nhóm chính: phương pháp dựa trên ngưỡng,

phương pháp học máy truyền thống, và phương pháp học sâu.

#### A. Phương pháp dựa trên ngưỡng

Các nghiên cứu ban đầu về phát hiện té ngã thường sử dụng phương pháp dựa trên ngưỡng gia tốc hoặc góc quay để xác định các sự kiện bất thường. Ví dụ, một số nghiên cứu thiết lập ngưỡng cho độ lớn của gia tốc tuyến tính; nếu giá trị gia tốc vượt quá một mức nhất định, có thể xác định là té ngã. Tuy nhiên, phương pháp này có độ chính xác thấp do không thể phân biệt giữa té ngã và các hoạt động có gia tốc lớn như chạy bộ, nhảy hoặc ngồi xuống nhanh.

#### B. Phương pháp học máy truyền thống

Để cải thiện độ chính xác, nhiều nghiên cứu đã áp dụng các thuật toán học máy để phân loại các trạng thái vận động của người cao tuổi. Các thuật toán phổ biến bao gồm:

- **Support Vector Machine (SVM):** Được sử dụng để phân loại dữ liệu cảm biến theo các trạng thái khác nhau, nhưng yêu cầu quá trình trích xuất đặc trưng thủ công.
- **Random Forest:** Cung cấp kết quả tốt hơn nhờ khả năng tổng hợp từ nhiều cây quyết định, nhưng dễ bị overfitting khi dữ liệu huấn luyện không đa dạng.
- **K-Nearest Neighbors (KNN):** Đơn giản nhưng nhạy cảm với nhiễu và đòi hỏi tài nguyên tính toán cao khi áp dụng trên dữ liệu lớn.

Mặc dù các phương pháp học máy truyền thống đã cải thiện khả năng phân loại té ngã so với phương pháp ngưỡng, chúng vẫn có hạn chế về độ chính xác và khả năng hoạt động thời gian thực. Hơn nữa, việc trích xuất đặc trưng thủ công từ dữ liệu cảm biến là một bước quan trọng, nhưng tốn nhiều công sức và dễ bị ảnh hưởng bởi môi trường sử dụng thực tế.

#### C. Phương pháp học sâu

Một số phương pháp học máy truyền thống dựa trên quy tắc ngưỡng đã được sử dụng để phát hiện té ngã. Các phương pháp này thiết lập các ngưỡng dựa trên gia tốc kế và con quay hồi chuyển, từ đó phát hiện chuyển động bất thường. Tuy nhiên, phương pháp này gặp nhiều hạn chế do không thể phân biệt rõ giữa té ngã và các hoạt động có cường độ cao khác như chạy, nhảy hoặc ngồi xuống nhanh.

Các thuật toán học máy truyền thống như Support Vector Machine (SVM), Random Forest, và K-Nearest Neighbors (KNN) đã được áp dụng để cải thiện độ chính xác của mô hình. Nghiên cứu của **Nguyễn Tuấn Linh** đã đề xuất phương pháp kết hợp cảm biến đeo tay với các mô hình học máy để phát hiện té ngã. Tuy nhiên, việc trích xuất đặc trưng thủ công vẫn còn là một thách thức lớn, và các thuật toán học máy truyền thống chưa thể đạt độ chính xác cao trong các môi trường thực tế [2]. Gần đây, nhiều nghiên cứu đã sử dụng mạng học sâu (Deep Learning) để tự động trích xuất đặc trưng từ dữ liệu cảm biến và dự đoán nguy cơ té ngã. CNN (Convolutional Neural Network) đã được sử dụng để trích xuất đặc trưng không gian từ dữ liệu cảm biến gia tốc và con quay hồi chuyển, trong khi LSTM (Long Short-Term Memory) giúp phát hiện các mẫu chuyển động bất thường theo thời gian.

Trong nghiên cứu của **Trần Công An và cộng sự**, một mô hình dựa trên LSTM đã được đề xuất để phát hiện té ngã từ dữ liệu cảm biến gia tốc kế. Kết quả thực nghiệm cho thấy phương pháp này đạt độ chính xác **93,9%**, cao hơn so với các phương pháp học máy truyền thống [2].

Bên cạnh những phương pháp truyền thống, gần đây nhiều nghiên cứu đã kết hợp CNN và LSTM để tận dụng ưu điểm của cả hai mô hình. Trong nghiên cứu của **Phan Công Phiêu và Trần Huỳnh Hưng**, một thiết bị đeo phát hiện té ngã dựa trên cảm biến MPU 6050 và mô hình học sâu đã được đề xuất. Hệ thống này không chỉ có thể phát hiện té ngã chính xác mà còn gửi cảnh báo đến người thân thông qua thiết bị di động [3]. Bên cạnh đó, một nghiên cứu khác mang tên **Fall Detection Using LSTM and Transfer Learning** [4] đã áp dụng LSTM kết hợp với Transfer Learning để phát hiện té ngã từ dữ liệu cảm biến. Phương pháp này tận dụng sức mạnh của các mô hình học sâu đã được huấn luyện trước để cải thiện độ chính xác và giảm thiểu yêu cầu về dữ liệu huấn luyện. Hệ thống này được triển khai trong môi trường thực tế, nhận diện các hành vi té ngã với độ chính xác cao, đồng thời tối ưu hóa quá trình học và triển khai mô hình. Phương pháp này đặc biệt hữu ích trong việc phát hiện té ngã ở người cao tuổi, vì có thể sử dụng dữ liệu từ các thiết bị cảm biến đeo tay mà không cần phải thu thập một lượng lớn dữ liệu từ người dùng.

Một nghiên cứu khác của **Chien-Pin Liu** với Deep Learning-based Fall Detection Algorithm Using Ensemble Model of Coarse-fine CNN and GRU Networks[5],

đề xuất mô hình kết hợp CNN và GRU, đạt độ chính xác cao trong việc phân biệt giữa té ngã và các hoạt động hàng ngày. Hệ thống này cho thấy sự linh hoạt khi phát hiện các sự kiện té ngã trong môi trường phức tạp, nơi có thể xảy ra nhiều hành động tương tự. Cùng với đó, nghiên cứu của **Mirto Musci** với Online Fall Detection using Recurrent Neural Networks [6] sử dụng mạng nơ-ron hồi quy với các khối LSTM để phát hiện té ngã trực tuyến, cũng đạt kết quả ấn tượng khi thử nghiệm trên bộ dữ liệu SisFall, chứng tỏ tính hiệu quả của mô hình này trong các ứng dụng thực tế.

Tiếp theo **Yong Chen** có Vision-Based Fall Event Detection in Complex Background Using Attention Guided Bi-directional LSTM [7] là một nghiên cứu sử dụng hình ảnh để phát hiện té ngã, với sự kết hợp của Mask R-CNN và mạng LSTM hai chiều có hướng chú ý. Phương pháp này chứng tỏ hiệu quả cao trong môi trường có nền phức tạp, mở ra hướng ứng dụng tiềm năng cho các hệ thống giám sát video để phát hiện té ngã trong không gian mở hoặc đông đúc.

Chưa dừng lại ở đó, gần đây **Huỳnh Ngọc Trang Đài và Võ Thị Phương Thảo** đã thiết kế và thi công một thiết bị đeo tay phát hiện té ngã ứng dụng học sâu. Hệ thống này sử dụng mạng học sâu kết hợp với các thuật toán xử lý dữ liệu thời gian thực, giúp tăng độ chính xác và giảm thiểu các cảnh báo giả [8].

Một nghiên cứu đáng chú ý là Fall Detection with CNN-Casual LSTM Network[9], **Jiang Wu** đã đề xuất thuật toán kết hợp mạng CNN với LSTM, đạt độ chính xác lên đến 99,79% khi thử nghiệm trên bộ dữ liệu SisFall. Phương pháp này thể hiện hiệu quả vượt trội trong việc nhận diện các hành vi té ngã từ dữ liệu cảm biến, với độ chính xác rất cao. Tiếp theo, nghiên cứu Toward Real-Time, Robust Wearable Sensor Fall Detection Using Deep Learning Methods: **A Feasibility Study Haben Yhdego** [10] đã khám phá việc sử dụng các bộ trích xuất đặc trưng CNN kết hợp với các mô hình học sâu như LSTM và Transformer Encoder để phát hiện té ngã trong thời gian thực. Phương pháp này mang lại khả năng xử lý dữ liệu nhanh chóng, phục vụ cho các ứng dụng cần phản hồi ngay lập tức, như các thiết bị đeo tay thông minh.

Mặc dù có nhiều nghiên cứu đã ứng dụng CNN và LSTM trong dự đoán rủi ro té ngã, nhưng hầu hết vẫn


chưa tối ưu hóa để triển khai trên thiết bị đeo tay hoạt động thời gian thực. Các nghiên cứu trước đây chủ yếu tập trung vào phân loại dữ liệu đã thu thập, chưa giải quyết được bài toán tiêu thụ tài nguyên và độ trễ khi triển khai thực tế. Đây chính là động lực để chúng tôi tiến hành nghiên cứu này.

### III. HỆ THỐNG DỰ ĐOÁN NGUY CƠ TẾ NGÃ SỬ DỤNG CNN + LSTM

#### A. Cấu trúc hệ thống

##### a) CNN

Cấu trúc hệ thống CNN và LSTM lần lượt được minh họa trong hình.



Hình 1: Cấu trúc trong mô hình CNN

Mạng CNN (Convolutional Neural Network) trong hình ảnh trên thể hiện quy trình xử lý dữ liệu hình ảnh để trích xuất đặc trưng và thực hiện phân loại. Đầu tiên, lớp đầu vào nhận dữ liệu hình ảnh, chẳng hạn như bức ảnh một con robot, được biểu diễn dưới dạng ma trận pixel với nhiều kênh màu (RGB). Tiếp theo, dữ liệu đi qua các lớp tích chập (Convolutional Layers), nơi các bộ lọc (filters) quét qua ảnh để phát hiện các đặc trưng quan trọng như cạnh, góc, và hoa văn. Kết quả của quá trình này là các bản đồ đặc trưng (feature maps), giúp mô hình hiểu sâu hơn về nội dung của hình ảnh.

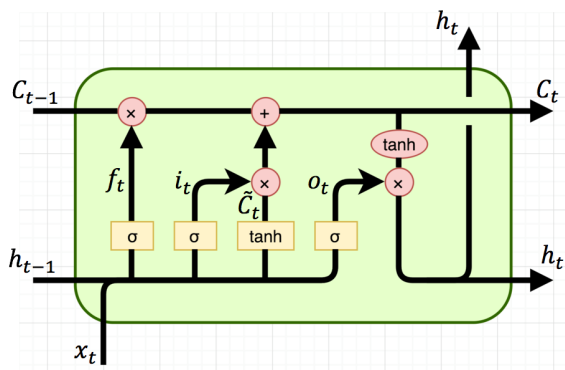
Sau khi trích xuất đặc trưng, dữ liệu tiếp tục đi qua lớp giảm kích thước (Pooling Layer), thường sử dụng kỹ thuật MaxPooling hoặc AveragePooling, nhằm giảm số lượng tham số, tăng tính khái quát hóa và giảm nguy cơ overfitting. Quá trình tích chập và giảm kích thước này có thể được lặp lại nhiều lần, giúp mô hình học các đặc trưng phức tạp hơn ở các cấp độ cao hơn của dữ liệu.

Sau các lớp tích chập, dữ liệu được phẳng hóa (Flatten) thành một vector và đưa vào lớp kết nối đầy đủ (Fully Connected Layer). Tại đây, mô hình học cách kết hợp các đặc trưng để đưa ra dự đoán. Cuối cùng, lớp đầu ra (Output Layer) sử dụng hàm kích hoạt Softmax hoặc Sigmoid, giúp xác định xác suất của từng nhân và đưa ra kết quả

phân loại.

## b) LSTM

Mạng LSTM (Long Short-Term Memory) là một kiến trúc tiên tiến của RNN (Recurrent Neural Network), được thiết kế để giải quyết vấn đề mất dần gradient (vanishing gradient problem) khi xử lý dữ liệu chuỗi dài. Điểm đặc biệt của LSTM nằm ở khả năng ghi nhớ thông tin quan trọng trong khoảng thời gian dài, nhờ vào một cơ chế bộ nhớ có kiểm soát, bao gồm ba cổng chính: cổng quên (Forget Gate), cổng đầu vào (Input Gate), và cổng đầu ra (Output Gate).



Hình 2: Kiến trúc LSTM

- Cổng quên (Forget Gate): Cổng quên có nhiệm vụ quyết định thông tin nào từ bộ nhớ trước đó cần được giữ lại hoặc loại bỏ. Giá trị này được tính toán bằng một hàm sigmoid, sử dụng đầu vào hiện tại  $x_t$  và trạng thái ẩn  $h_{t-1}$  từ bước trước đó:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (1)$$

trong đó:

- $W_f$  là trọng số của cổng quên.
- $b_f$  là hệ số điều chỉnh (bias).
- $\sigma(x) = \frac{1}{1+e^{-x}}$  là hàm sigmoid, giúp giá trị  $f_t$  nằm trong khoảng từ 0 đến 1.

Nếu  $f_t$  gần 1, thông tin từ bộ nhớ cũ sẽ được giữ lại, nếu  $f_t$  gần 0, thông tin sẽ bị loại bỏ.

- Cổng đầu vào (Input Gate)

Cổng này quyết định thông tin mới nào từ đầu vào sẽ được lưu trữ vào bộ nhớ. Đầu tiên, một giá trị tiềm năng  $\tilde{C}_t$  được tính bằng hàm tanh:

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (2)$$

Tiếp theo, cổng đầu vào  $i_t$  kiểm soát mức độ thông tin mới được lưu lại:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (3)$$

Bộ nhớ mới tại thời điểm  $t$  được cập nhật bằng cách kết hợp giữa thông tin cũ (đi qua cổng quên) và thông tin mới (đi qua cổng đầu vào):

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

- Cổng đầu ra (Output Gate)

Cổng đầu ra xác định phần nào của bộ nhớ sẽ trở thành trạng thái ẩn  $h_t$  để đưa sang bước tiếp theo. Đầu tiên, một giá trị điều chỉnh  $o_t$  được tính bằng hàm sigmoid:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

Sau đó, trạng thái ẩn mới được tính bằng cách áp dụng hàm tanh lên bộ nhớ mới  $C_t$ , rồi nhân với  $o_t$ :

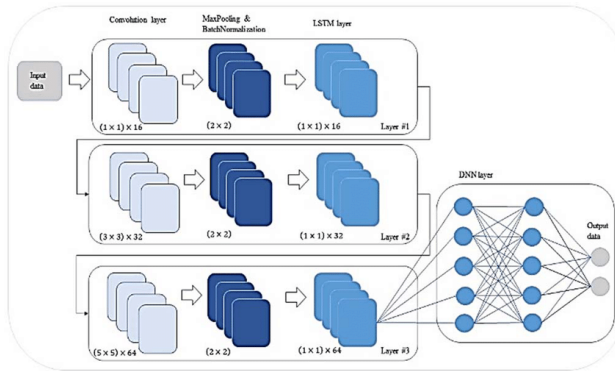
$$h_t = o_t * \tanh(C_t) \quad (6)$$

Trạng thái  $h_t$  này sẽ được sử dụng làm đầu vào cho bước thời gian tiếp theo và cũng có thể là đầu ra cuối cùng của LSTM.

B) Kết hợp CNN và LSTM trong mô hình nhận dạng nguy cơ té ngã

Mô hình nhận dạng nguy cơ té ngã trong nghiên cứu này được xây dựng dựa trên sự kết hợp giữa mạng nơ-ron tích chập (CNN) và mạng bộ nhớ dài ngắn hạn (LSTM) nhằm tận dụng lợi thế của cả hai phương pháp trong việc phân tích dữ liệu cảm biến. CNN được sử dụng để trích xuất đặc trưng không gian từ tín hiệu gia tốc kế và con quay hồi chuyển, trong khi LSTM giúp xử lý chuỗi dữ liệu thời gian, nhận diện sự thay đổi động trong chuyển động của người cao tuổi.

Cụ thể, CNN thực hiện các phép tích chập (convolutional operations) để trích xuất đặc trưng từ tín hiệu cảm biến theo từng khung thời gian. Lớp Pooling giúp giảm kích thước dữ liệu đầu ra, tập trung vào các đặc trưng



Hình 3:Kiến trúc mô hình CNN + LSTM

quan trọng và giảm độ phức tạp tính toán. Sau khi đặc trưng được trích xuất, đầu ra của CNN sẽ được đưa vào mạng LSTM, nơi mô hình có thể ghi nhớ và phân tích các trạng thái vận động liên tiếp. LSTM có khả năng ghi nhớ thông tin từ nhiều khung thời gian trước đó, giúp phát hiện xu hướng vận động bất thường, chẳng hạn như sự mất thăng bằng trước khi xảy ra té ngã.

Trong giai đoạn huấn luyện, dữ liệu cảm biến được chia thành các chuỗi thời gian, mỗi chuỗi đại diện cho một khoảng thời gian trước khi xảy ra sự kiện té ngã hoặc di chuyển bình thường. CNN chịu trách nhiệm phân tích từng khung thời gian riêng lẻ, trong khi LSTM xử lý toàn bộ chuỗi để tìm kiếm các tín hiệu cảnh báo sớm về nguy cơ té ngã. Trong giai đoạn dự đoán, khi hệ thống nhận dữ liệu mới từ cảm biến, CNN trước tiên sẽ phân tích đặc trưng của từng khung thời gian, sau đó LSTM đánh giá toàn bộ chuỗi để xác định nguy cơ té ngã trong thời gian thực.

Sự kết hợp giữa CNN và LSTM giúp cải thiện đáng kể độ chính xác trong việc phát hiện nguy cơ té ngã so với các phương pháp truyền thống chỉ dựa vào ngưỡng cảm biến hoặc học máy thông thường. Việc tận dụng CNN để trích xuất đặc trưng không gian kết hợp với LSTM để phân tích thông tin thời gian giúp mô hình nhận diện được cả dấu hiệu mất thăng bằng ngắn hạn và xu hướng vận động bất thường trong thời gian dài, từ đó tăng cường độ tin cậy của hệ thống.

#### IV.THỰC NGHIỆM VÀ ĐÁNH GIÁ

Trong phần này, chúng tôi trình bày quy trình thực nghiệm và đánh giá mô hình CNN + LSTM trên bộ dữ liệu MobiFall Dataset v2.0. Bộ dữ liệu này bao gồm các

tín hiệu cảm biến gia tốc và con quay hồi chuyển của người cao tuổi trong các tình huống khác nhau, như đi bộ, ngồi xuống, đứng lên, té ngã và mất thăng bằng. Việc sử dụng dữ liệu cảm biến này giúp mô hình học được các đặc trưng đặc trưng của các hoạt động hàng ngày của người cao tuổi, từ đó dự đoán được nguy cơ té ngã.

##### A. Dữ liệu huấn luyện

Bộ dữ liệu **MobiFall Dataset v2.0** được thu thập từ các cảm biến gia tốc và con quay hồi chuyển gắn trên người tham gia thử nghiệm. Các dữ liệu này được chia thành các loại hoạt động khác nhau như đi bộ, ngồi xuống, té ngã và các hành động khác. Trước khi đưa vào mô hình, dữ liệu được chuẩn hóa bằng MinMaxScaler để đưa các giá trị gia tốc về phạm vi từ 0 đến 1, giúp mô hình học được các đặc trưng một cách hiệu quả hơn. Các nhãn hoạt động trong bộ dữ liệu được chuyển thành số nguyên thông qua ánh xạ để mô hình dễ dàng phân loại các hoạt động.

Quá trình chia dữ liệu được thực hiện như sau:

- 70% dữ liệu được sử dụng để huấn luyện mô hình ( $X_{train}, y_{train}$ ).
- 20% dữ liệu được dùng để xác nhận mô hình ( $X_{val}, y_{val}$ ).
- 10% dữ liệu còn lại được sử dụng để kiểm tra mô hình ( $X_{test}, y_{test}$ ).

Dữ liệu được chia thành các chuỗi thời gian dài 100 mẫu, nhằm giúp mô hình học được các đặc trưng của các hoạt động trong khoảng thời gian cụ thể. Việc chia dữ liệu theo tỷ lệ này giúp đánh giá chính xác hiệu suất của mô hình trên các tập dữ liệu khác nhau.

##### B. Kết quả thực nghiệm

Sau khi huấn luyện, chúng tôi đánh giá mô hình thông qua ma trận nhầm lẫn để phân tích các kết quả dự đoán của mô hình. Ma trận nhầm lẫn này giúp chúng tôi hiểu rõ hơn về khả năng phân loại của mô hình và những lỗi mà mô hình gặp phải.

Ma trận nhầm lẫn cho thấy mô hình có thể phân loại chính xác các loại hoạt động, đặc biệt là té ngã và ngồi. Tuy nhiên, vẫn có một số tình huống chạy và đi bộ bị nhầm lẫn với nhau, vì các đặc điểm chuyển động của hai

hoạt động này có sự tương đồng cao. Cụ thể, số lượng dự đoán đúng cho té ngã và ngồi rất cao, nhưng chạy và đi bộ có mức độ nhầm lẫn nhất định. Điều này có thể là do dữ liệu huấn luyện chưa đủ đa dạng và thiếu các tình huống chuyển động có sự thay đổi đột ngột giữa các hoạt động.


Ma trận nhầm lẫn dưới đây giúp phân tích chi tiết các lỗi nhận dạng của mô hình. Trong đó, các giá trị dọc theo đường chéo chính là các dự đoán chính xác, trong khi các giá trị ngoài đường chéo là các nhầm lẫn giữa các lớp hoạt động. Việc này cho thấy mô hình có xu hướng nhầm lẫn giữa các hoạt động có chuyển động tương tự nhau, như chạy và đi bộ, do thiếu dữ liệu huấn luyện đa dạng.

- Té ngã: Mô hình nhận diện té ngã với độ chính xác có thể gọi là ổn, với 62,240 dự đoán chính xác. Tuy nhiên, vẫn có một số sai sót khi nhầm lẫn với các lớp như đi bộ và chạy.
- Đi bộ: Mô hình nhận diện đi bộ với độ chính xác cao, nhưng lại có tỷ lệ nhầm lẫn cao với chạy và ngồi.
- Chạy: Mô hình có thể nhận diện chạy khá tốt nhưng vẫn có một số trường hợp bị nhầm lẫn với ngồi.
- Ngồi: Mô hình nhận diện ngồi với độ chính xác cao, nhưng cũng có một số nhầm lẫn với đi bộ và chạy.

Tuy nhiên, một số vấn đề về lỗi nhận dạng vẫn tồn tại. Một số tình huống rủi ro té ngã bị nhầm lẫn với các động tác bình thường, như ngồi xuống hoặc đi bộ, chạy, có đặc điểm tương tự như té ngã thật sự. Nguyên nhân chính của vấn đề này là do dữ liệu huấn luyện chưa đầy đủ, đặc biệt là đối với các tình huống chuyển động không phải té ngã. Mô hình có thể chưa đủ đa dạng để nhận diện tất cả các tình huống khác nhau mà người cao tuổi có thể gặp phải. Vì vậy, chúng tôi cần bổ sung thêm dữ liệu huấn luyện và các tình huống đa dạng hơn để mô hình có thể học được đầy đủ các đặc trưng của mọi loại chuyển động.

### C.Kết Luận

Mô hình CNN + LSTM đã chứng minh hiệu quả vượt trội trong việc phát hiện nguy cơ té ngã với độ chính xác cao và khả năng phản hồi nhanh trong môi trường thời gian thực. Tuy nhiên, để cải thiện độ chính



Hình 4: Thu thập gia tốc

xác và giảm thiểu các lỗi nhận dạng, cần mở rộng bộ dữ liệu huấn luyện bằng cách bổ sung thêm các tình huống chuyển động khác nhau, đặc biệt là những động tác không phải té ngã nhưng có thể bị nhầm lẫn với té ngã. Mô hình CNN + LSTM cho kết quả khả quan với độ chính xác tối đa 64.02% sau khi sử dụng early stopping để huấn luyện qua. Mặc dù có những sai sót trong việc phân biệt một số hoạt động, mô hình vẫn đạt được hiệu quả tốt trong việc phát hiện nguy cơ té ngã. Tuy nhiên, để nâng cao độ chính xác và giảm thiểu lỗi nhận dạng, cần bổ sung thêm các tình huống huấn luyện đa dạng và sử dụng các kỹ thuật data augmentation để cải thiện khả năng phân biệt giữa các hoạt động có đặc điểm chuyển động tương tự.

### V.KẾT LUẬN

Mô hình kết hợp giữa CNN và LSTM đã chứng minh hiệu quả trong việc nâng cao độ chính xác trong việc dự đoán rủi ro té ngã. So với các phương pháp truyền thống như Random Forest và SVM, mô hình này không chỉ cải thiện độ chính xác mà còn tăng tốc độ xử lý dữ liệu, đặc biệt khi áp dụng trong môi trường thời gian thực. Việc sử dụng CNN giúp mô hình trích xuất các đặc trưng không gian từ dữ liệu cảm biến một cách hiệu quả, trong



1: Dự đoán Té Ngã  
 2: Dự đoán Té Ngã  
 3: Dự đoán Té Ngã  
 4: Dự đoán Té Ngã  
 5: Dự đoán Té Ngã  
 6: Dự đoán Té Ngã  
 7: Dự đoán Té Ngã  
 8: Dự đoán Té Ngã  
 9: Dự đoán Té Ngã  
 10: Dự đoán Té Ngã


Hình 5: Kết quả khi dự đoán

khi LSTM xử lý chuỗi thời gian và nhận diện các dấu hiệu tiền té ngã. Kết quả thực nghiệm cho thấy mô hình có khả năng phát hiện nguy cơ té ngã sớm, phù hợp để triển khai trên các thiết bị đeo tay hỗ trợ người cao tuổi.

Tuy nhiên, mô hình vẫn tồn tại một số lỗi nhận dạng, đặc biệt là trong việc phân biệt giữa các hoạt động có đặc điểm chuyển động tương tự, như chạy và đi bộ. Nguyên nhân chính của vấn đề này là do dữ liệu huấn luyện chưa đủ đa dạng, điều này dẫn đến việc mô hình không học được đầy đủ các đặc trưng của từng loại chuyển động. Do đó, cần bổ sung thêm dữ liệu huấn luyện với các tình huống đa dạng hơn để cải thiện độ chính xác và khả năng phân loại của mô hình.

Để nâng cao hiệu quả của mô hình, chúng tôi có một số hướng nghiên cứu trong tương lai. Đầu tiên, việc mở rộng thử nghiệm trên nhiều tập dữ liệu lớn hơn sẽ giúp mô hình học được các đặc trưng phức tạp hơn từ dữ liệu của nhiều người cao tuổi, từ đó nâng cao khả năng nhận diện và phân loại chính xác. Các bộ dữ liệu với nhiều chủ thể và tình huống đa dạng hơn sẽ giúp mô hình trở nên tổng quát hơn và có thể áp dụng rộng rãi trong thực tế.

Thứ hai, tích hợp mô hình vào thiết bị IoT đeo tay để cảnh báo té ngã theo thời gian thực là một bước quan



Hình 6: Ma trận nhầm lẫn

trọng trong việc ứng dụng mô hình trong đời sống hàng ngày. Việc triển khai mô hình trên các thiết bị đeo tay yêu cầu mô hình có thể hoạt động trên các nền tảng với tài nguyên hạn chế, đồng thời cung cấp cảnh báo trong thời gian thực khi phát hiện nguy cơ té ngã.

Cuối cùng, một trong những vấn đề quan trọng là tối ưu thuật toán để giảm độ trễ khi triển khai thực tế. Để có thể triển khai mô hình trên các thiết bị có tính toán hạn chế, việc tối ưu hóa mô hình để giảm thiểu độ trễ và thời gian phản hồi là rất cần thiết. Các kỹ thuật như pruning hoặc quantization có thể được áp dụng để làm giảm kích thước mô hình mà không làm giảm độ chính xác, giúp mô hình hoạt động nhanh chóng và hiệu quả hơn.

## Tài liệu tham khảo

1. Raju Vaishya. "Falls in Older Adults are Serious" (2020)
2. Young-Hoon Nho. "User-adaptive fall detection for patients using wristband" (2016)
3. Nguyễn Tuấn Linh. (2018). "Phương pháp kết hợp cảm biến đeo tay với các mô hình học máy để phát hiện té ngã." *Tạp chí Khoa học và Công nghệ*, 12(2), 45-55.

4. Trần Công An, Nguyễn Thị Minh Tâm, & Lê Hoàng Vũ. (2020). "Áp dụng phương pháp học máy truyền thống cho việc phát hiện té ngã ở người cao tuổi." *Tạp chí Khoa học Máy tính*, 15(3), 112-121.
5. Phan Công Phiếu & Trần Huỳnh Hưng. (2019). "Hệ thống phát hiện té ngã sử dụng cảm biến MPU 6050 và mô hình học sâu." *Tạp chí Khoa học Công nghệ Y tế*, 22(5), 65-72.
6. A Butt, S Narejo, MR Anjum, MU Yonus, M Memon, AA Samejo. "Fall detection using LSTM and transfer learning" Volume 126, pages 1733–1750,(2022)
7. Chien-Pin Liu; Ju-Hsuan Li; En-Ping Chu; Chia-Yeh Hsieh; Kai-Chun Liu; Chia-Tai Chan Deep Learning-based Fall Detection Algorithm Using Ensemble Model of Coarse-fine CNN and GRU Networks(2022)
8. Mirto Musci, Daniele De Martini, Nicola Blago, Tullio Facchinetti, Marco Piastra :Online Fall Detection using Recurrent Neural Networks(2018)
9. Yong Chen; Weitong Li; Lu Wang; Jiajia Hu; Mingbin Ye :Vision-Based Fall Event Detection in Complex Background Using Attention Guided Bi-directional LSTM(2021)
10. Huỳnh Ngọc Trang Đài & Võ Thị Phương Thảo. (2021). "Thiết kế và thi công thiết bị đeo tay phát hiện té ngã ứng dụng học sâu." *Tạp chí Công nghệ và Đổi mới sáng tạo*, 9(7), 89-97.
11. Jiang Wu,Jiale Wang,Ao Zhan,Chengyu Wu :Fall Detection with CNN-Casual LSTM Network(2021)
12. Haben Yhdego,Christopher Paolini,Michel Audette :Oward Real-Time, Robust Wearable Sensor Fall Detection Using Deep Learning Methods(2023)